

Rapport d'Analyse des Transactions E-commerce

Difficultés rencontrées lors du nettoyage des données

La phase de nettoyage des données a constitué une étape essentielle pour garantir la fiabilité des analyses. Plusieurs problèmes de qualité des données ont été identifiés dans le jeu de données.

Tout d'abord, la présence de valeurs manquantes dans les colonnes **Description** et **CustomerID** a nécessité un traitement spécifique. Les descriptions manquantes ont été supprimées afin d'éviter toute ambiguïté lors de l'analyse des produits, tandis que les identifiants clients manquants ont été remplacés par la valeur "*Unknown*" afin de préserver les transactions concernées.

Ensuite, le dataset contenait des **lignes dupliquées** susceptibles de fausser les résultats statistiques et les indicateurs de performance. Ces doublons ont été détectés puis supprimés.

L'une des principales difficultés a concerné la validation des données numériques. Les colonnes **Quantity** et **UnitPrice** comportaient des valeurs négatives et des valeurs extrêmes. Les valeurs négatives ont été considérées comme invalides dans le cadre de l'analyse des ventes et ont été remplacées par la médiane de chaque sous groupe. Pour les valeurs aberrantes (outliers), la méthode de l'**Intervalle Interquartile (IQR)** a été utilisée afin d'identifier et d'éliminer les observations susceptibles de biaiser les résultats.

Enfin, certaines descriptions de produits contenaient des entrées invalides ou incohérentes qui ont également été supprimées afin d'améliorer la qualité globale du dataset.

Principaux insights

L'analyse exploratoire des données a permis de mettre en évidence plusieurs tendances importantes.

Le premier constat est que les produits les plus vendus appartiennent majoritairement à la catégorie des **objets décoratifs et des articles liés aux événements festifs**, révélant une forte demande pour ce type de produits.

Le deuxième insight concerne l'évolution temporelle des ventes. Les résultats montrent une **forte croissance du chiffre d'affaires entre les mois d'août et de novembre**, traduisant une saisonnalité marquée et une augmentation significative de l'activité commerciale à l'approche des fêtes de fin d'année.

Enfin, l'analyse géographique révèle que le **Royaume-Uni constitue de loin le marché le plus rentable** pour l'entreprise. Ce pays génère la majorité des revenus observés dans le dataset et représente le principal moteur de croissance de l'activité.

Conclusion

Ce projet a permis de mettre en pratique l'ensemble des étapes fondamentales d'un processus d'analyse de données : compréhension du dataset, nettoyage, validation des données, analyse exploratoire et visualisation. Les résultats obtenus montrent l'importance de la qualité des données pour produire des analyses fiables et exploitables.

L'étude a également permis d'identifier des opportunités commerciales concrètes, notamment en renforçant les actions marketing sur les produits les plus populaires, en anticipant les pics saisonniers de demande et en consolidant la présence de l'entreprise sur son marché principal. Ces enseignements peuvent servir de base à des analyses plus avancées, telles que la segmentation client ou la prévision des ventes.